


Analiza struktury

Kamil Wilak
Uniwersytet Ekonomiczny w Poznaniu


Rozkład normalny $N(\mu, \sigma)$

- ▶ Niech X oznacza dzienną stopę zwrotu
- ▶ Niech X ma rozkład normalny $N(0, 0.1)$
- ▶ Ile wynosi prawdopodobieństwo, że dzienna stopa zwrotu przyjmuje wartość z przedziału $(-0.1, 0.1)$?




Rozkład normalny $N(\mu, \sigma)$

- ▶ Niech X oznacza dzienną kurs EUR/PLN
- ▶ Niech X ma rozkład normalny $N(4.5, 0.05)$
- ▶ Ile wynosi prawdopodobieństwo, że dzienna kurs jest mniejszy niż 4.4?




Rozkład normalny $N(\mu, \sigma)$



- ▶ μ – wartość oczekiwana
- ▶ σ – odchylenie standardowe
- ▶ $x \in \mathbb{R}$
- ▶ $N(0,1)$ – rozkład normalny standaryzowany


Rozkład normalny $N(\mu, \sigma)$

Reguła 3σ




Typy rozkładów


- prawostronna
- lewostronna




Asymetria umiarkowana




Asymetria skrajna




Rozkład spłaszczony/wysmukły



Rozkład jednomodalny



Rozkład bimodalny



Rozkład wielomodalny

Szeregi statystyczne

Założenie 1. Niech dany będzie szereg szczegółowy cechy ilościowej X dla n -elementowej zbiorowości statystycznej:

$$x_1, x_2, \dots, x_n,$$

gdzie wartości x_i posortowane są rosnąco.

Założenie 2. Niech dany będzie szereg strukturalny punktowy cechy ilościowej skokowej X o k poziomach dla n -elementowej populacji:

Poziomy cechy X (x_i)	Liczebności poziomów (n_i)
x_1	n_1
x_2	n_2
$\vdots$	$\vdots$
x_k	n_k

gdzie $n_1 + \dots + n_k = n$.

Szeregi statystyczne

Założenie 3. Niech dany będzie szereg strukturalny przedziałowy cechy ilościowej X o k przedziałach klasowych dla n -elementowej populacji:

Przedziały klasowe cechy X	Liczebności przedziałów (n_i)
$[x_0, x_1)$	n_1
$[x_1, x_2)$	n_2
$\vdots$	$\vdots$
$[x_{k-1}, x_k)$	n_k

gdzie $n_1 + \dots + n_k = n$. Oznaczmy przez x'_i środek i -tego przedziału klasowego, tj. $x'_i = \frac{x_i + x_{i-1}}{2}$

Analiza struktury

Analiza struktury polega na opisie zbiorowości statystycznej ze względu na badane cechy zmienne. W przypadku cech ilościowych na kompleksową analizę struktury składają się:

- ▶ **analiza tendencji centralnej** – służąca do określania tych wartości badanej cechy, które są typowe dla danej zbiorowości, wokół których skupiają się pozostałe wartości,
- ▶ **analiza rozproszenia (zróźnicowania, zmienności, dyspersji)** – służąca do badania stopnia zróźnicowania wartości zmiennej wokół wartości typowych,
- ▶ **analiza asymetrii (skośności)** – służące do badania kierunku zróźnicowania wartości cechy względem średniej,
- ▶ **analiza koncentracji** – polegająca na określeniu stopnia koncentracji wokół wartości centralnych / intensywności występowania wartości skrajnych.

Analiza struktury

Analiza struktury bazuje na dwóch typach miar:

- ▶ **miary klasyczne** – obliczane na podstawie wszystkich obserwacji,
- ▶ **miary pozycyjne** – obliczane na podstawie wybranych obserwacji.

Uwaga 1. Miary klasyczne stosujemy do opisu rozkładów jednorodnych, bądź względnie jednorodnych, a więc takich, które spełniają następujące warunki:

- (1) są jednomodalne,
- (2) są symetryczne bądź umiarkowanie asymetryczne,
- (3) cechują się umiarkowanym zróżnicowaniem i koncentracją.

Uwaga 2. Miary klasyczne są wrażliwe na wartości odstające.

Klasyfikacja miar w analizie struktury

Miary klasyczne	Miary pozycyjne
Analiza tendencji centralnej	
średnia arytmetyczna ($\bar{x}$)	mediana (Me) kwartyl 1. (Q_1) kwartyl 3. (Q_3) dominanta (D)
Analiza zmienności	
wariancja (S^2) odchylenie standardowe (S) współczynnik zmienności (V)	odchylenie ćwiartkowe (Q) pozycyjny współczynnik zmienności (V_Q)
Analiza asymetrii	
trzeci moment centralny stand. (α_3)	pozycyjny współczynnik asymetrii (A_Q)
klasyczno-pozycyjny współczynnik asymetrii (A_s)	
Analiza koncentracji	
czwarty moment centralny stand. (α_4) współczynnik ekscesu (K')	

Średnia arytmetyczna

szereg szczegółowy:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

szereg strukturalny punktowy:

$$\bar{x} = \frac{\sum_{i=1}^k x_i n_i}{n} = \frac{x_1 n_1 + x_2 n_2 + \dots + x_k n_k}{n}$$

szereg strukturalny przedziałowy:

$$\bar{x} = \frac{\sum_{i=1}^k x'_i n_i}{n} = \frac{x'_1 n_1 + x'_2 n_2 + \dots + x'_k n_k}{n}$$

Wariancja

populacja

szereg szczegółowy:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

szereg strukturalny punktowy:

$$s^2 = \frac{\sum_{i=1}^k (x_i - \bar{x})^2 n_i}{n}$$

szereg strukturalny przedziałowy:

$$s^2 = \frac{\sum_{i=1}^k (x'_i - \bar{x})^2 n_i}{n}$$

Wariancja

próba

szereg szczegółowy:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

szereg strukturalny punktowy:

$$s^2 = \frac{\sum_{i=1}^k (x_i - \bar{x})^2 n_i}{n - 1}$$

szereg strukturalny przedziałowy:

$$s^2 = \frac{\sum_{i=1}^k (x'_i - \bar{x})^2 n_i}{n - 1}$$

Wariancja

- ▶ wyrażona w kwadracie jednostek badanej cechy
- ▶ nie podlega interpretacji

Odchylenie standardowe

$$S = \sqrt{S^2}$$

- ▶ Miara bezwzględna, wyrażona w jednostkach badanej cechy
- ▶ Interpretacja: przeciętne odchylenie wartości badanej cechy od średniej

Współczynnik zmienności

$$V = \frac{S}{\bar{X}} \quad (\cdot 100\%)$$

- ▶ Miara względna, pozbawiona jednostek
- ▶ Interpretacja:
 - $V \in (0, 20]$ – słabe zróżnicowanie,
 - $V \in (20, 40]$ – umiarkowane zróżnicowanie,
 - $V \in (40, 70]$ – silne zróżnicowanie,
 - $V \in (70, +\infty)$ – bardzo silne zróżnicowanie.

Współczynnik skośności/asymetrii

populacja

Inaczej **trzeci moment centralny standaryzowany**

szereg szczegółowy:

$$\alpha_3 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

szereg strukturalny punktowy:

$$\alpha_3 = \frac{\frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^3 n_i}{s^3}$$

szereg strukturalny przedziałowy:

$$\alpha_3 = \frac{\frac{1}{n} \sum_{i=1}^k (x'_i - \bar{x})^3 n_i}{s^3}$$

Współczynnik skośności/asymetrii

próba

szereg szczegółowy:

$$\alpha_3 = \frac{n}{(n-1)(n-2)} \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{S^3}$$

szereg strukturalny punktowy:

$$\alpha_3 = \frac{n}{(n-1)(n-2)} \frac{\sum_{i=1}^k (x_i - \bar{x})^3 n_i}{S^3}$$

szereg strukturalny przedziałowy:

$$\alpha_3 = \frac{n}{(n-1)(n-2)} \frac{\sum_{i=1}^k (x'_i - \bar{x})^3 n_i}{S^3}$$

Współczynnik skośności/asymetrii

- ▶ Miara względna, pozbawiona jednostek
- ▶ Interpretacja – kierunek asymetrii:
 - $\alpha_3 < 0$ - rozkład lewostronnie asymetryczny
 - $\alpha_3 = 0$ - rozkład symetryczny
 - $\alpha_3 > 0$ - rozkład prawostronnie asymetryczny
- ▶ Interpretacja – siła asymetrii:
 - $|\alpha_3| \in (0; 0.25)$ - słaba
 - $|\alpha_3| \in [0.25; 0.5)$ - umiarkowana
 - $|\alpha_3| \in [0.5; \infty)$ - silna
- ▶ Asymetria a miary tendencji centralnej:
 - rozkład lewostronnie asymetryczny $\rightarrow \bar{x} < Me < D$:
większość jednostek ma wartość większą niż średnia
 - rozkład prawostronnie asymetryczny $\rightarrow D < Me < \bar{x}$:
większość jednostek ma wartość mniejszą niż średnia

Kurtoza, Współczynnik ekscesu

populacja

Kurtoza = czwarty moment centralny standaryzowant

Kurtoza

szereg szczegółowy:

$$K = \alpha_4 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{S^4}$$

szereg strukturalny punktowy:

$$K = \alpha_4 = \frac{\frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^4 n_i}{S^4}$$

szereg strukturalny przedziałowy:

$$K = \alpha_4 = \frac{\frac{1}{n} \sum_{i=1}^k (x'_i - \bar{x})^4 n_i}{S^4}$$

Kurtoza = Czwarty moment centralny standaryzowany

Współczynnik ekscesu

$$K' = K - 3$$

Kurtoza, Współczynnik ekscesu

próba

Kurtoza

szereg szczegółowy:

$$K = \alpha_4 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{S^4}$$

szereg strukturalny punktowy:

$$K = \alpha_4 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \frac{\sum_{i=1}^k (x_i - \bar{x})^4 n_i}{S^4}$$

szereg strukturalny przedziałowy:

$$K = \alpha_4 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \frac{\sum_{i=1}^k (x'_i - \bar{x})^4 n_i}{S^4}$$

Kurtoza = Czwarty moment centralny standaryzowany


Współczynnik ekscesu

$$K' = K - \frac{3(n-1)^2}{(n-2)(n-3)}$$

Kurtoza, Współczynnik ekscesu


- ▶ Miara względna, pozbawiona jednostek
- ▶ $K < 3 \iff K' < 0$ – rozkład platokurtyczny (spłaszczony):
 - koncentracja wokół wartości centralnych słabsza niż w rozkładzie normalnym
 - intensywność wartości skrajnych słabsza niż w rozkładzie normalnym
- ▶ $K = 3 \iff K' = 0$ – rozkład mezokurtyczny:
 - koncentracja wokół wartości centralnych taka jak w w rozkładzie normalnym
 - intensywność wartości skrajnych taka jak w rozkładzie normalnym
- ▶ $K > 3 \iff K' > 0$ – rozkład leptokurtyczny (wysmukły):
 - koncentracja wokół wartości centralnych silniejsza niż w rozkładzie normalnym
 - intensywność wartości skrajnych silniejsza niż w rozkładzie normalnym

Kurtoza, Współczynnik ekscesu



Excess Kurtosis of various distributions (Source: Wikimedia Commons under CC0)


Kwartyle




- ▶ (Co najmniej) 25% jednostek przyjmuje wartości badanej cechy mniejsze (nie większe) niż Q_1 .
- ▶ (Co najmniej) 50% jednostek przyjmuje wartości badanej cechy mniejsze (nie większe) niż Me .
- ▶ (Co najmniej) 75% jednostek przyjmuje wartości badanej cechy mniejsze (nie większe) niż Q_3 .

Kwartyle - algorytmy wyznaczania


algorytm $n - 1$



algorytm n



algorytm $n + 1$



Mediana / Kwartył 2.

szereg szczegółowy, strukturalny punktowy:

$$Me = \begin{cases} x_{\lfloor n/2 \rfloor + 1} & \text{gdy } n \text{ nieparzyste,} \\ \frac{x_{n/2} + x_{n/2+1}}{2} & \text{gdy } n \text{ parzyste.} \end{cases}$$

szereg strukturalny przedziałowy:

$$Me = x_{Me} + \frac{\frac{1}{2}n - \sum_{i=1}^{k_{Me}-1} n_i}{n_{Me}} c_{Me}$$

- ▶ x_{Me} – początek przedziału, w którym znajduje się mediana,
- ▶ $\sum_{i=1}^{k_{Me}-1} n_i$ – suma liczebności przedziałów poprzedzających ten, w którym znajduje się mediana,
- ▶ n_{Me} – liczebność przedziału, w którym znajduje się mediana,
- ▶ c_{Me} – szerokość przedziału, w którym znajduje się mediana,
- ▶ przedział, w którym znajduje się mediana, to ten, dla którego dystrybuanta empiryczna osiąga najmniejszą wartość większą bądź równą 0,5.

Kwartył 1.

szereg szczegółowy, strukturalny punktowy:

$$Q_1 = x_{[q_1]} + (q_1 - [q_1])(x_{[q_1]} - x_{[q_1]}), \quad \text{gdzie } q_1 = \frac{1}{4}(n-1) + 1$$

$$Q_1 = (1-d) \cdot x_k + d \cdot x_{k+1}, \quad \text{gdzie } d = q_1 - k, \quad k = [q_1], \quad q_1 = \frac{1}{4}(n-1) + 1$$

Algorytm $n-1$

szereg strukturalny przedziałowy:

$$Q_1 = x_{Q_1} + \frac{\frac{1}{4}n - \sum_{i=1}^{k_{Q_1}-1} n_i}{n_{Q_1}} c_{Q_1}$$

- ▶ x_{Q_1} – początek przedziału, w którym znajduje się kwartył 1.,
- ▶ $\sum_{i=1}^{k_{Q_1}-1} n_i$ – suma liczebności przedziałów poprzedzających ten, w którym znajduje się kwartył 1.,
- ▶ n_{Q_1} – liczebność przedziału, w którym znajduje się kwartył 1.,
- ▶ c_{Q_1} – szerokość przedziału, w którym znajduje się kwartył 1.,
- ▶ przedział, w którym znajduje się kwartył 1., to ten, dla którego dystrybuenta empiryczna osiąga najmniejszą wartość większą bądź równą 0,25.

Kwartył 3.

szereg szczegółowy:

$$Q_3 = x_{\lfloor q_3 \rfloor} + (q_3 - \lfloor q_3 \rfloor)(x_{\lceil q_3 \rceil} - x_{\lfloor q_3 \rfloor}), \quad \text{gdzie } q_3 = \frac{3}{4}(n-1) + 1$$

$$Q_3 = (1-d) \cdot x_k + d \cdot x_{k+1}, \quad \text{gdzie } d = q_3 - k, \quad k = \lfloor q_3 \rfloor, \quad q_3 = \frac{3}{4}(n-1) + 1$$

Algorytm $n-1$

szereg strukturalny przedziałowy:

$$Q_3 = x_{Q_3} + \frac{\frac{3}{4}n - \sum_{i=1}^{k_{Q_3}-1} n_i}{n_{Q_3}} c_{Q_3}$$

- ▶ x_{Q_3} – początek przedziału, w którym znajduje się kwartył 3.,
- ▶ $\sum_{i=1}^{k_{Q_3}-1} n_i$ – suma liczebności przedziałów poprzedzających ten, w którym znajduje się kwartył 3.,
- ▶ n_{Q_3} – liczebność przedziału, w którym znajduje się kwartył 3.,
- ▶ c_{Q_3} – szerokość przedziału, w którym znajduje się kwartył 3.,
- ▶ przedział, w którym znajduje się kwartył 3., to ten, dla którego dystrybuanta empiryczna osiąga najmniejszą wartość większą bądź równą 0.75.

Dominanta / Moda

szereg strukturalny przedziałowy:

$$D = x_D + \frac{n_D - n_{D-1}}{2n_D - n_{D-1} - n_{D+1}} c_D$$

- ▶ x_D – początek przedziału, w którym znajduje się dominanta,
- ▶ n_D – liczebność przedziału, w którym znajduje się dominanta,
- ▶ n_{D-1} – liczebność przedziału, poprzedzającego ten, w którym znajduje się dominanta,
- ▶ n_{D+1} – liczebność przedziału, po tym, w którym znajduje się dominanta,
- ▶ c_D – szerokość przedziału, w którym znajduje się dominanta,
- ▶ przedział, w którym znajduje się dominanta, to ten, który cechuje się największą liczebnością.

Odchylenie ćwiartkowe

Pozycyjny współczynnik zmienności

Odchylenie ćwiartkowe

$$Q = \frac{Q_3 - Q_1}{2}$$

- Interpretacja: Przeciętne odchylenie wartości badanej cechy od mediany.

Pozycyjny współczynnik zmienności

$$V_Q = \frac{Q}{Me} \quad (\cdot 100\%)$$

- Interpretacja: jak w przypadku V .

Pozycyjny współczynnik asymetrii

Klasyczno-pozycyjny współczynnik asymetrii

Pozycyjny współczynnik asymetrii

$$A_Q = \frac{Q_1 + Q_3 - 2Me}{2Q}$$

- Interpretacja: jak w przypadku α_3 z tym, że dotyczy 50% środkowych obserwacji.

Klasyczno-pozycyjny współczynnik asymetrii

$$As = \frac{\bar{x} - D}{S}$$

- Interpretacja: jak w przypadku α_3 .

Uwagi do wyznaczania miar w szeregu strukturalnym przedziałowym

Uwaga 1. Miary klasyczne stosujemy tylko wtedy, gdy wszystkie przedziały klasowe są ograniczone i równej długości.

Uwaga 2. Gdy wszystkie przedziały klasowe są równej długości, z wyjątkiem pierwszego lub ostatniego, który jest otwarty (nieograniczony), a jego liczebność maksymalnie sięga 5% wszystkich obserwacji – w przypadku jednego otwartego przedziału – lub 3% wszystkich obserwacji – w przypadku dwóch otwartych przedziałów – to można taki przedział domknąć, dając mu długość taką jaką mają pozostałe przedziały. Dzięki takiemu zabiegowi można zastosować miary klasyczne.

Uwaga 3. Dominanty nie wyznaczamy, gdy najliczniejszy jest pierwszy bądź ostatni przedział klasowy.

Funkcje programu Excel

dla szeregu szczegółowego

Miara	Funkcja
średnia arytmetyczna	ŚREDNIA
wariancja (populacja)	WARIANCJA.POP
wariancja (próba)	WARIANCJA.PRÓBKI
odchylenie standardowe (populacja)	ODCH.STAND.POPUL
odchylenie standardowe (próba)	ODCH.STANDARD.PRÓBKI
współczynnik asymetrii (populacja)	SKOŚNOŚĆ.P
współczynnik asymetrii (próba)	SKOŚNOŚĆ
kurtoza (próba)	KURTOZA
mediana	MEDIANA
kwartył (algorytm $n - 1$)	KWARTYL.PRZEDZ.ZAMK