

Analiza współzależności cech jakościowych

Kamil Wilak
Uniwersytet Ekonomiczny w Poznaniu

Tabela kontyngencji

		Cecha Y				$n_{i.}$
		Y_1	Y_2	$\dots$	Y_k	
Cecha X	X_1	n_{11}	n_{12}	$\dots$	n_{1k}	$n_{1.}$
	X_2	n_{21}	n_{22}	$\dots$	n_{2k}	$n_{2.}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
	X_w	n_{w1}	n_{w2}	$\dots$	n_{wk}	$n_{w.}$
$n_{.j}$		$n_{.1}$	$n_{.2}$	$\dots$	$n_{.k}$	n

- ▶ Cecha X przyjmuje w wariantów, zaś cecha Y przyjmuje k wariantów.
- ▶ Symbole n_{ij} ($i = 1, 2, \dots, w, j = 1, 2, \dots, k$) to częstości empiryczne, które oznaczają liczbę jednostek posiadających jednocześnie wariant X_i cechy X i wariant Y_j cechy Y .
- ▶ Liczebność brzegowa $n_{i.}$ będąca sumą i -tego wiersza, oznacza liczbę jednostek, które przyjmują wariant x_i cechy X , natomiast wartość brzegowa $n_{.j}$ będąca sumą j -tej kolumny, oznacza liczbę jednostek, które przyjmują wariant Y_j cechy Y .
- ▶ Symbol n oznacza liczebność zbiorowości, przy czym zachodzi $n = \sum_{i=1}^w \sum_{j=1}^k n_{ij} = \sum_{i=1}^w n_{i.} = \sum_{j=1}^k n_{.j}$.

Statystyka χ^2

$$\chi^2 = \sum_{i=1}^w \sum_{j=1}^k \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$$

- ▶ n_{ij} – liczebności empiryczne
- ▶ $\hat{n}_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}$ – liczebności teoretyczne

Statystyka χ^2

		Cecha Y	
		Y_1	Y_2
Cecha X	X_1	a	b
	X_2	c	d

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}$$

Statystyka χ^2 z poprawką Yatesa

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(|n_{ij} - \hat{n}_{ij}| - 0,5)^2}{\hat{n}_{ij}}$$

- ▶ n_{ij} – liczebności empiryczne
- ▶ $\hat{n}_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}$ – liczebności teoretyczne

Poprawkę Yatesa stosuje się w sytuacji, gdy występują małe liczebności teoretyczne (mniejsze niż 5).

Miary współzależności

- ▶ Współczynnik T-Czuprowa

$$T = \sqrt{\frac{\chi^2}{n\sqrt{(w-1)(k-1)}}$$

- ▶ Współczynnik V-Cramera

$$V = \sqrt{\frac{\chi^2}{n \cdot \min\{w-1, k-1\}}}$$

- ▶ Współczynnik C-Pearsona

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

- ▶ Skorygowany współczynnik C-Pearsona

$$C_{kor} = \frac{C}{C_{max}}$$

gdzie

$$C_{max} = \frac{\sqrt{\frac{w-1}{w}} + \sqrt{\frac{k-1}{k}}}{2}$$

Miary współzależności

- ▶ Współczynniki T , V i C_{kor} przyjmują wartości z przedziału $[0, 1]$, gdzie 0 oznacza brak zależności, natomiast 1 zależność idealną (deterministyczną). W celu interpretacji ich wartości można przyjąć pewne umowne progi:
 - ▶ $(0.0; 0.2)$ - słaby związek pomiędzy cechami,
 - ▶ $[0.2; 0.5)$ - umiarkowany związek pomiędzy cechami,
 - ▶ $[0.5; 1.0)$ silny związek pomiędzy cechami.
- ▶ Maksymalna wartość współczynnika C-Pearsona zależy od liczby kategorii badanych cech. W celu unormowania tego wskaźnika do przedziału $[0, 1]$ wyznacza się jego skorygowaną wersję. Korekta polega na podzieleniu go przez maksymalną wartość, jaką dla danych liczb kategorii w i k może teoretycznie przyjąć.
- ▶ W przypadku, gdy cechy X i Y mają tyle samo kategorii ($w = k$), współczynniki V-Cramera i T-Czuprowa są równe.