


Analiza współzależności cech ilościowych

Kamil Wilak
Uniwersytet Ekonomiczny w Poznaniu

Wykres rozrzutu



Współczynnik korelacji liniowej Pearsona

Cecha X	Cecha Y
x_1	y_1
x_2	y_2
$\vdots$	$\vdots$
x_n	y_n

$$r_{xy} = \frac{Cov(X, Y)}{S_x S_y}$$

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Współczynnik korelacji liniowej Pearsona


Interpretacja – kierunek

- ▶ $r_{xy} < 0$ – korelacja ujemna
- ▶ $r_{xy} > 0$ – korelacja dodatnia

Interpretacja – siła

- ▶ $|r_{xy}| = 0$ – brak
- ▶ $0 < |r_{xy}| \leq 0.2$ – bardzo słaba
- ▶ $0.2 < |r_{xy}| \leq 0.4$ – słaba
- ▶ $0.4 < |r_{xy}| \leq 0.7$ – umiarkowana
- ▶ $0.7 < |r_{xy}| \leq 0.9$ – silna
- ▶ $0.9 < |r_{xy}| < 1.0$ – bardzo silna
- ▶ $|r_{xy}| = 1$ – idealna

Współczynnik korelacji liniowej Pearsona



Współczynnik korelacji liniowej Pearsona

Macierz korelacji cech X , Y , Z

$$P = \begin{bmatrix} 1 & r_{XY} & r_{XZ} \\ r_{YX} & 1 & r_{YZ} \\ r_{ZX} & r_{ZY} & 1 \end{bmatrix}$$

Współczynnik korelacji rang Spearmana

- ▶ jest to współczynnik korelacji liniowej Pearsona obliczony na rangach wartości cech

$$r_S = \frac{\text{Cov}(R_X, R_Y)}{S_{R_X} S_{R_Y}},$$

gdzie R_X i R_Y to rangi odpowiednio cechy X i Y .

- ▶ nadawanie rang polega na posortowaniu wartości każdej z cech (osobno) rosnąco i przypisanie kolejnych wartości od 1 do n ; jeśli jakaś wartość powtarza się, wówczas wyznaczamy wartość tzw. rangi wiązanej – średniej arytmetycznej z pozycji, na których ta wartość się znajduje
- ▶ w przypadku braku rang wiązanych:

$$r_S = 1 - \frac{6 \sum_{i=1}^n (r_{x,i} - r_{y,i})^2}{n(n^2 - 1)}$$

gdzie $r_{x,i}$ i $r_{y,i}$ to rangi cechy X i Y przypisane i -tej obserwacji, n to liczba obserwacji.

Współczynnik korelacji liniowej Spearmana

- ▶ przyjmuje wartości z przedziału $[-1, 1]$
- ▶ jego interpretacja jest podobna jak interpretacja współczynnika korelacji liniowej Pearsona, znak oznacza kierunek, zaś odległość od zera wskazuje na siłę
- ▶ jest bardziej odporny na obserwacje odstające niż współczynnik korelacji liniowej Pearsona
- ▶ pokazuje dowolną monotoniczną współzależność (także nieliniową)
- ▶ zależy wyłącznie od uporządkowania zaobserwowanych wartości
- ▶ można go stosować w przypadku cech ilościowych oraz jakościowych mierzonych na skali porządkowej

Rodzaje korelacji liniowej

- ▶ **całkowita** – współzależność tylko między dwiema cechami, bez wnikania w ich powiązania z innymi cechami
- ▶ **częstkowa** – współzależność między dwiema cechami z wyłączeniem wpływu cech pozostałych
- ▶ **wieloraka** – współzależność wybranej cechy ze wszystkimi pozostałymi łącznie.

Korelacja cząstkowa

$$r_{XY.Z} = \frac{-P_{12}}{\sqrt{P_{11}P_{22}}} = \frac{r_{XY} - r_{XZ}r_{YZ}}{\sqrt{(1 - r_{XZ}^2)(1 - r_{YZ}^2)}}$$

- ▶ P_{ij} – dopełnienie algebraiczne macierzy korelacji P

Korelacja cząstkowa

Przykładem jest dodatnia korelacja między poziomem zniszczeń spowodowanych pożarem a liczbą strażaków pracujących przy gaszeniu danego pożaru. Okazuje się, że im więcej jest strażaków, tym poziom zniszczeń również jest większy – czy to oznacza, że strażacy dokonują zniszczeń? Nie, ponieważ jeśli w tym związku uwzględnimy wielkość samego pożaru, wspomniana korelacja zanika.

Korelacja wieloraka

$$r_{X.YZ} = \sqrt{1 - \frac{|P|}{P_{11}}} = \sqrt{\frac{r_{XY}^2 + r_{XZ}^2 - 2r_{XY}r_{XZ}r_{YZ}}{1 - r_{YZ}^2}}$$

- ▶ P – macierz korelacji
- ▶ P_{ij} – dopełnienie algebraiczne macierzy korelacji P